

PROPOSAL

Analisis Prediktif Performa Ujian Siswa Menggunakan Machine Learning



Oleh

Nama: Salman Rachmadi

NIM: 203012420009

Magister Informatika

Telkom University

Bandung

April 2026

Daftar Isi

1. Introduction
2. Objective
3. Data Source
4. Methodology
5. Expected Outcome
6. Literature Review
7. Timeline
8. References

1. Introduction

Performa ujian siswa dipengaruhi oleh banyak faktor, bukan hanya kemampuan kognitif. Okano et al. (2023) membuktikan bahwa durasi tidur per malam memiliki hubungan kuat dengan GPA mahasiswa. Malakeh et al. (2022) menemukan bahwa semakin banyak waktu di media sosial, semakin menurun prestasi akademik siswa. Faktor-faktor perilaku seperti ini perlu dipahami lebih dalam untuk menjelaskan hasil belajar, bukan hanya melihat nilai akhir.

Khan dan Ghosh (2021) mencatat bahwa teknik klasifikasi dan clustering paling sering digunakan dalam studi prediksi performa siswa. Data pendidikan berdimensi tinggi dan mengandung pola yang sulit ditangkap analisis konvensional. Algoritma *machine learning* mampu mengidentifikasi pola-pola tersebut untuk prediksi dan rekomendasi.

Proyek ini menggunakan dataset **Student Exam Performance** dari Kaggle dengan 10.000 siswa dan 23 fitur. Fitur-fitur tersebut terbagi dalam empat kategori: (1) demografis, mencakup jenis kelamin, usia, pendidikan orang tua, pendapatan keluarga, dan akses internet; (2) perilaku belajar, termasuk jam belajar harian, tingkat kehadiran, durasi tidur, waktu media sosial, tingkat penyelesaian tugas, skor partisipasi, jumlah kursus online, dan status bimbingan belajar; (3) nilai akademik, yaitu skor per mata pelajaran (matematika, membaca, menulis, sains), nilai ujian akhir, dan GPA sebelumnya; (4) variabel hasil, yaitu status kelulusan (Pass/Fail) dan kategori nilai (A sampai F).

Hasil analisis ini bermanfaat bagi beberapa pihak. Guru dan sekolah dapat mendeteksi siswa yang berpotensi mengalami kesulitan belajar sejak awal. Pembuat kebijakan dapat mengalokasikan sumber daya, seperti program bimbingan belajar, secara lebih tepat sasaran. Orang tua siswa dapat memahami faktor-faktor yang berpengaruh terhadap performa anak dan menciptakan lingkungan belajar yang lebih mendukung di rumah.

2. Objective

Proyek ini menjawab tiga pertanyaan penelitian utama. Setiap pertanyaan penelitian diiringi oleh satu hipotesis yang diuji melalui metode analisis spesifik.

Pertanyaan Penelitian

Tabel 1. Pertanyaan penelitian dan metode analisis

#	Pertanyaan Penelitian	Metode Analisis
RQ1	Faktor perilaku belajar apa yang paling berkorelasi dengan performa ujian siswa?	Korelasi Pearson, uji-t, ANOVA
RQ2	Seberapa efektif model klasifikasi ML dalam memprediksi kelulusan siswa (Pass/Fail)?	Logistic Regression, Random Forest Classifier
RQ3	Rekomendasi intervensi apa yang sesuai untuk setiap profil siswa yang teridentifikasi?	K-Means Clustering, profiling

Hipotesis

Tabel 2. Hipotesis penelitian

ID	Hipotesis
H1	Jam belajar per hari (*study_hours_per_day*) berkorelasi positif dan jam media sosial (*social_media_hours*) berkorelasi negatif dengan nilai ujian akhir
H2	Random Forest Classifier menghasilkan performa yang lebih baik dibanding Logistic Regression dalam memprediksi kelulusan siswa
H3	Siswa dapat dikelompokkan ke dalam beberapa cluster dengan karakteristik dan kebutuhan intervensi yang berbeda berdasarkan pola perilaku belajar mereka

3. Data Source

Proyek ini menggunakan **Student Exam Performance Dataset** yang tersedia secara publik di Kaggle. Dataset ini memuat data 10.000 siswa dengan 23 kolom fitur. Hasil pemeriksaan awal menunjukkan tidak ada *missing values* maupun data duplikat, sehingga dataset ini siap untuk dianalisis lebih lanjut. Berikut rincian struktur dataset.

Ringkasan Dataset

Tabel 3. Ringkasan dataset

Atribut	Detail
Jumlah record	10.000 siswa
Jumlah fitur	23 kolom
Missing values	Tidak ada
Data duplikat	Tidak ada

Struktur Fitur

Fitur Kategorikal (8 kolom):

Tabel 4. Fitur kategorikal dalam dataset

Fitur	Jumlah Kategori	Nilai
gender	2	Male, Female
parental_education	4	High School, Bachelor, Master, PhD
family_income	3	Low, Medium, High
internet_access	2	Yes, No
study_environment	3	Quiet, Moderate, Noisy
tutoring	2	Yes, No
pass_fail	2	Pass, Fail
grade_category	5	A, B, C, D, F

Fitur Numerikal (14 kolom):

Tabel 5. Fitur numerikal dalam dataset

Fitur	Tipe	Range
age	Integer	15–18
study_hours_per_day	Float	0.50–7.24
attendance_rate	Float	~67–100
sleep_hours	Float	~4–10
social_media_hours	Float	0–~8
assignment_completion_rate	Float	0–100
participation_score	Float	0–100
online_courses_completed	Integer	0–6
math_score	Float	~4–98
reading_score	Float	~4–98
writing_score	Float	~4–98
science_score	Float	~4–98
final_exam_score	Float	~4–98
previous_gpa	Float	0–4.0

Variabel Target

Tabel 6. Variabel target

Target	Tipe	Deskripsi
`final_exam_score`	Regresi (continuous)	Nilai ujian akhir (mean=49.68, std=12.15)
`pass_fail`	Klasifikasi biner	Pass (48.6%) / Fail (51.4%)
`grade_category`	Klasifikasi multikelas	A (0.1%), B (0.9%), C (9.0%), D

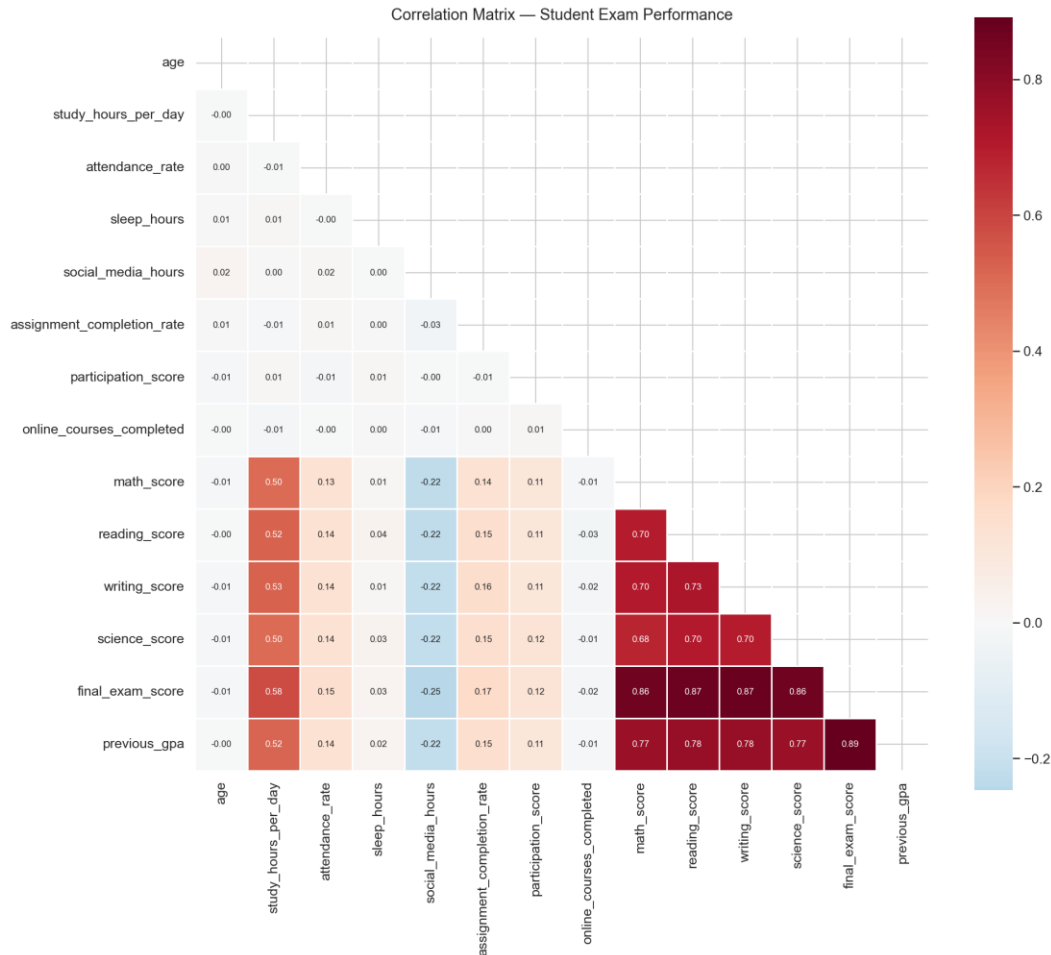
		(38.3%), F (51.7%)
--	--	--------------------

Korelasi Awal dengan `final\_exam\_score`

Sebelum menyusun metodologi, kami melakukan eksplorasi awal untuk melihat korelasi masing-masing fitur dengan nilai ujian akhir. Tabel berikut menunjukkan sepuluh fitur dengan koefisien korelasi Pearson tertinggi terhadap `final_exam_score`.

Tabel 7. Korelasi Pearson fitur terhadap `final_exam_score`

Fitur	Korelasi (r)
<code>previous_gpa</code>	0.8912
<code>writing_score</code>	0.8745
<code>reading_score</code>	0.8725
<code>math_score</code>	0.8639
<code>science_score</code>	0.8627
<code>study_hours_per_day</code>	0.5758
<code>social_media_hours</code>	-0.2463
<code>assignment_completion_rate</code>	0.1707
<code>attendance_rate</code>	0.1506
<code>participation_score</code>	0.1239



Gambar 1. Correlation Matrix

4. Methodology

Analisis dalam proyek ini mengikuti kerangka kerja **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*). Proyek ini terbagi ke dalam tiga fase analisis, masing-masing menjawab satu pertanyaan penelitian dan menguji satu hipotesis.

Fase 1: Analisis Korelasi dan Uji Statistik (RQ1 + H1)

Fase ini bertujuan mengidentifikasi faktor-faktor perilaku belajar yang memiliki hubungan paling kuat dengan nilai ujian akhir. Langkah-langkah yang dilakukan:

- **Korelasi Pearson** untuk mengukur kekuatan hubungan linear antara fitur perilaku (jam belajar, jam media sosial, jam tidur, tingkat kehadiran, tingkat penyelesaian tugas) dengan `final_exam_score`

- **Independent *t*-test** untuk membandingkan rata-rata nilai antar kelompok berdasarkan `internet_access` dan `tutoring`
- **One-way ANOVA** untuk menguji apakah terdapat perbedaan rata-rata kebiasaan belajar yang signifikan antar kategori `grade_category`
- **Visualisasi** pendukung berupa *scatter plot*, *heatmap* korelasi, dan *box plot* per kelompok

Fase 2: Klasifikasi ML (RQ2 + H2)

Pada fase ini, kami membangun dan membandingkan dua model klasifikasi untuk memprediksi apakah seorang siswa lulus atau tidak (`pass_fail`). Model yang digunakan:

- **Logistic Regression** sebagai model *baseline* yang bersifat linear
- **Random Forest Classifier** sebagai model *ensemble* yang mampu menangkap hubungan non-linear

Tahapan preprocessing meliputi encoding variabel kategorikal (binary dan ordinal), standardisasi fitur numerik menggunakan `StandardScaler`, serta pembuatan fitur turunan (*feature engineering*) seperti *engagement score* dan *study efficiency*. Kami mengevaluasi model menggunakan metrik Accuracy, Precision, Recall, F1-Score, Confusion Matrix, dan 5-fold cross-validation. Hasil perbandingan kedua model digunakan untuk menguji H2.

Fase 3: Clustering dan Rekomendasi (RQ3 + H3)

Fase terakhir berfokus pada pengelompokan siswa berdasarkan pola perilaku belajar mereka. Langkah-langkahnya:

- Penerapan **K-Means Clustering** pada fitur perilaku siswa
- Penentuan jumlah cluster (K) yang optimal menggunakan **Elbow Method** dan **Silhouette Score**
- **Profiling** setiap cluster berdasarkan karakteristik rata-rata (jam belajar, nilai, tingkat kelulusan)
- Penyusunan **rekomendasi intervensi** yang disesuaikan untuk masing-masing profil cluster

Tools & Framework

Seluruh analisis dilakukan menggunakan bahasa pemrograman **Python 3.x** dengan *library* dan *tools* berikut:

Tabel 8. Tools dan framework yang digunakan

Kategori	Tools
Manipulasi data	pandas, numpy
Visualisasi	matplotlib, seaborn
Machine learning	scikit-learn
Uji statistik	scipy, statsmodels
Lingkungan kerja	Jupyter Notebook

5. Expected Outcome

Dari tiga fase analisis yang direncanakan, proyek ini menghasilkan beberapa *output* berikut.

Pertama, terkait RQ1, proyek ini menghasilkan bukti statistik mengenai fitur-fitur perilaku belajar yang paling berkorelasi dengan performa ujian. Berdasarkan eksplorasi awal, kami menduga jam belajar per hari menunjukkan korelasi positif, sedangkan jam penggunaan media sosial menunjukkan korelasi negatif. Hasil analisis ini dilengkapi dengan nilai korelasi dan *p-value* dari setiap uji statistik.

Kedua, terkait RQ2, kami membangun dua model klasifikasi, Logistic Regression dan Random Forest, beserta perbandingan performa keduanya menggunakan metrik Accuracy, Precision, Recall, dan F1-Score. Model dengan performa terbaik kami rekomendasikan sebagai model utama untuk prediksi kelulusan siswa.

Ketiga, terkait RQ3, siswa kami kelompokkan ke dalam beberapa cluster berdasarkan pola perilaku belajar mereka. Setiap cluster diprofilkan berdasarkan karakteristik rata-ratanya, lalu dari profil tersebut kami susun rekomendasi intervensi yang spesifik.

Misalnya, cluster dengan jam belajar rendah dan tingkat kehadiran tinggi membutuhkan pendekatan berbeda dengan cluster yang memiliki jam belajar tinggi tetapi nilai rendah.

Keempat, seluruh hipotesis (H1 sampai H3) kami uji dan nyatakan diterima atau ditolak berdasarkan bukti statistik dan hasil eksperimen.

Kelima, hasil analisis kami sajikan dalam bentuk visualisasi yang komunikatif agar dapat dipahami oleh berbagai pihak, termasuk yang tidak memiliki latar belakang teknis.

6. Literature Review

Bagian ini meninjau penelitian terbaru yang relevan dengan topik dan metodologi proyek. Tinjauan disusun berdasarkan tiga area yang berkaitan langsung dengan hipotesis penelitian: faktor perilaku belajar dan performa akademik, penerapan klasifikasi *machine learning* pada data pendidikan, serta teknik clustering untuk profil siswa dan rekomendasi intervensi.

6.1 Faktor Perilaku Belajar dan Performa Akademik (H1)

Okano et al. (2023) melakukan penelitian longitudinal terhadap mahasiswa tahun pertama. Mereka menemukan bahwa durasi tidur per malam dapat memprediksi GPA. Setiap jam tidur yang hilang berkaitan dengan penurunan GPA sebesar 0.07 poin. Efeknya lebih terasa pada siswa yang tidur kurang dari enam jam per malam. Pola tidur yang tampak sederhana ternyata punya kontribusi nyata terhadap pencapaian akademik.

Malakeh et al. (2022) melaporkan korelasi negatif antara kecanduan media sosial dan performa akademik. Mekanisme utamanya adalah *time displacement*, yaitu waktu yang seharusnya digunakan untuk belajar tergeser oleh aktivitas di media sosial. Semakin lama seorang siswa menghabiskan waktu di media sosial, semakin sedikit waktu yang tersisa untuk kegiatan belajar.

Feraco et al. (2023) menunjukkan bahwa kebiasaan belajar teratur dan motivasi intrinsik merupakan prediktor kuat terhadap nilai siswa. Mereka membangun model terintegrasi yang menghubungkan *soft skills*, kegiatan ekstrakurikuler, dan regulasi diri dalam belajar dengan pencapaian akademik. Hasilnya memperkuat pandangan bahwa jam belajar per hari punya hubungan positif dengan performa ujian.

Plak et al. (2022) mengembangkan sistem peringatan dini (*early warning system*) untuk pendidikan tinggi. Tingkat kehadiran dan tingkat penyelesaian tugas muncul sebagai indikator andal untuk memprediksi apakah seorang siswa akan mengalami kesulitan atau tidak. Kedua variabel ini relevan untuk dimasukkan ke dalam analisis korelasi pada RQ1.

6.2 Klasifikasi Machine Learning untuk Prediksi Performa Siswa (H2)

Yağcı (2022) menerapkan kerangka kerja CRISP-DM untuk memprediksi performa akademik menggunakan beberapa algoritma. Hasilnya menunjukkan bahwa CRISP-DM bisa diandalkan untuk proyek *educational data mining* dari awal sampai akhir. Hal ini menjadi alasan kerangka ini dipilih dalam proyek kami.

Alkan et al. (2025) membandingkan empat algoritma, yaitu C5.0, CART, SVM, dan Random Forest, pada 613 siswa di Turki. Random Forest menunjukkan performa paling konsisten dalam 10-fold cross-validation dengan akurasi 74.3%. Model ini kemudian dijadikan dasar untuk membangun sistem deteksi dini kegagalan akademik. Studi ini meyakinkan bahwa Random Forest adalah pilihan tepat untuk tugas klasifikasi serupa.

Chen dan Zhai (2023) menguji beberapa algoritma pada dataset performa siswa. Kesimpulan mereka cukup jelas: model *ensemble* seperti Random Forest cenderung mengungguli model linear dalam tugas klasifikasi. Hal ini sesuai dengan hipotesis H2 yang menyatakan bahwa Random Forest menghasilkan performa lebih baik dibanding Logistic Regression.

Rakitina dan Qureshi (2023) membandingkan Logistic Regression dan Random Forest untuk memprediksi kualifikasi siswa berdasarkan nilai paruh semester. Kedua algoritma memiliki keunggulan masing-masing tergantung karakteristik data, namun Random Forest menunjukkan stabilitas lebih tinggi secara konsisten. Temuan ini relevan untuk pengujian H2 dalam proyek ini.

Dari sisi pemilihan fitur, Hussain dan Khan (2023) menemukan bahwa menggabungkan data akademik sebelumnya (seperti GPA) dengan data perilaku belajar menghasilkan prediksi paling akurat. Ini memberikan justifikasi untuk memasukkan `previous_gpa` sebagai salah satu fitur dalam model klasifikasi kami.

6.3 Clustering dan Rekomendasi Intervensi (H3)

Ouassif et al. (2025) menggunakan K-Means Clustering pada data *engagement* siswa, seperti frekuensi bertanya, kunjungan ke materi belajar, dan partisipasi dalam diskusi. Mereka memvalidasi jumlah cluster menggunakan Elbow Method dan Silhouette Score, lalu membangun sistem rekomendasi berbasis *collaborative filtering* untuk tiap cluster. Empat profil siswa berhasil diidentifikasi, masing-masing dengan kebutuhan intervensi yang berbeda. Pendekatan ini sangat mirip dengan apa yang kami lakukan pada Fase 3 proyek ini.

Matz et al. (2023) menunjukkan bahwa menggabungkan metrik *engagement* dengan data sosio-demografis menghasilkan profil siswa yang lebih kaya dan informatif. Hal ini mendukung rencana kami untuk menggunakan fitur perilaku dan demografis secara bersamaan dalam proses clustering.

Khan dan Ghosh (2021) dalam tinjauan sistematik mereka mencatat bahwa teknik clustering, khususnya K-Means dan hierarchical, termasuk yang paling banyak dipakai dalam studi *educational data mining*. Bersama dengan metode klasifikasi seperti Random Forest dan SVM, teknik-teknik ini terbukti efektif dalam berbagai konteks pendidikan. Tinjauan ini memberikan landasan bagi keseluruhan pilihan metodologi dalam proyek ini.

7. Timeline

Tabel 9. Timeline proyek

Minggu	Aktivitas	Deliverable
8 (Apr 25)	Proposal submission	Proposal dokumen
9	Data cleaning, preprocessing, feature engineering	Progress Report 1
10–12	EDA, visualisasi, uji statistik	Progress Report 2
13–15	Modeling, analisis, kompilasi laporan	Final Report
16	Presentasi	Slide presentasi

8. References

- Alkan, B. B., Kuzucuk, S., Alkan, N., & Sinan, A. (2025). Using machine learning to predict student outcomes for early intervention and formative assessment. *Scientific Reports*, 15, 39797. <https://doi.org/10.1038/s41598-025-23409-w>
- Chen, Y., & Zhai, L. (2023). Comparative study of student performance prediction using machine learning. *Education and Information Technologies*, 28, 12039–12057. <https://doi.org/10.1007/s10639-023-11672-1>
- Feraco, T., et al. (2023). An integrated model of school students' academic achievement and life satisfaction: Linking soft skills, extracurricular activities, self-regulated learning, motivation, and emotions. *European Journal of Psychology of Education*, 38, 109–130. <https://doi.org/10.1007/s10212-022-00601-4>
- Hussain, S., & Khan, M. Q. (2023). Student-Performulator: Predicting students' academic performance at secondary and intermediate level using machine learning. *Annals of Data Science*, 10, 637–655. <https://doi.org/10.1007/s40745-021-00341-0>
- Khan, A., & Ghosh, S. K. (2021). Student performance analysis and prediction in classroom learning: A review of educational data mining studies. *Education and Information Technologies*, 26(1), 205–240. <https://doi.org/10.1007/s10639-020-10230-3>
- Malakeh, Z., et al. (2022). Correlation between psychological factors, academic performance, and social media addiction: Model-based testing. *Behavior and Information Technology*, 41(8), 1583–1595. <https://doi.org/10.1080/0144929X.2021.1891460>
- Matz, C., et al. (2023). Using machine learning to predict student retention from socio-demographic characteristics and app-based engagement metrics. *Scientific Reports*, 13, 5705. <https://doi.org/10.1038/s41598-023-32484-w>
- Okano, K., et al. (2023). Nightly sleep duration predicts GPA in first-year college students. *Proceedings of the National Academy of Sciences*, 120(12), e2209123120. <https://doi.org/10.1073/pnas.2209123120>

Ouassif, K., Ziani, B., Herrera-Tapia, J., & Kerrache, C. A. (2025). Empowering education: Leveraging clustering and recommendations for enhanced student insights. *Education Sciences*, 15(7), 819. <https://doi.org/10.3390/educsci15070819>

Plak, S., Cornelisz, I., Meeter, M., & van Klaveren, C. (2022). Early warning systems for more effective student counselling in higher education: Evidence from a Dutch field experiment. *Higher Education Quarterly*, 76(1), 131–152. <https://doi.org/10.1111/hequ.12298>

Rakitina, T., & Qureshi, R. (2023). Logistic Regression and Random Forest comparison in predicting students' qualification based on students' half-semester performance. *IEEE Xplore*. <https://doi.org/10.1109/ITQM59423.2023.10262783>

Yağcı, M. (2022). Educational data mining: Prediction of students' academic performance using machine learning algorithms. *Smart Learning Environment*, 9, 11. <https://doi.org/10.1186/s40561-022-00192-z>