

Pendahuluan

Web scraping adalah teknik untuk mengekstrak data dari halaman website secara otomatis. Laporan ini menjelaskan implementasi web scraping menggunakan Python dengan library requests, BeautifulSoup, dan pandas.

Sumber Referensi: <https://www.tencentcloud.com/techpedia/102401>

Langkah-Langkah Web Scraping

1. Instalasi Library

Langkah pertama adalah menginstall library yang diperlukan:

```
!pip install requests beautifulsoup4 pandas
```

Catatan: Browser yang digunakan untuk inspect element adalah Opera.

2. Memilih Halaman Web Target

Contoh yang digunakan adalah artikel berita dari detik.com dengan URL:

```
https://news.detik.com/internasional/d-8382337/iran-klaim-hancurkan-radar-  
militer-terbesar-as-di-qatar
```

Cara Inspect Element:

1. Buka halaman web yang akan di-scrape
2. Klik kanan pada judul berita/headline
3. Pilih "Inspect Element"
4. Hasil yang diperoleh: elemen h1 dengan class detail__title

3. Kode Implementasi

```
import requests  
from bs4 import BeautifulSoup  
import pandas as pd  
  
# URL of the news page  
url = 'https://news.detik.com/internasional/d-8382337/...'  
  
# Send a request to the website  
response = requests.get(url)  
  
# Parse the HTML content  
soup = BeautifulSoup(response.text, 'html.parser')  
  
# Find news headlines  
headlines = soup.find_all('h1', class_='detail__title')  
  
# Extract text and store in a list  
news_list = []  
for headline in headlines:  
    news_list.append(headline.text.strip())
```

```
# Display the results  
print(news_list)
```

Hasil Output:

```
['Iran Klaim Hancurkan Radar Militer Terbesar AS di Qatar']
```

Jawaban Pertanyaan

Jawaban Nomor 1: Penjelasan Library yang Di-install

Library yang di-install terdiri dari tiga library utama:

1. REQUESTS

- Fungsi: Library untuk mengirim HTTP requests ke website
- Kegunaan: Mengambil konten HTML dari halaman web
- Contoh: `response = requests.get(url)`
- Tanpa library ini, kita harus membuat koneksi HTTP secara manual

2. BEAUTIFULSOUP4

- Fungsi: Library untuk parsing dan menavigasi dokumen HTML/XML
- Kegunaan: Mengekstrak data dari HTML dengan mudah
- Contoh: `soup.find_all("h1", class_="detail_title")`
- Tanpa library ini, kita harus parsing HTML secara manual

3. PANDAS

- Fungsi: Library untuk manipulasi dan analisis data
- Kegunaan: Menyimpan data dalam format terstruktur (DataFrame)
- Contoh: `df = pd.DataFrame(news_list)`
- Bisa export ke CSV/Excel

Kenapa Perlu Di-install?

- Library-library ini bukan bagian dari Python standard library
- requests: API lebih simple dan user-friendly dibanding urllib
- beautifulsoup4: Tidak ada HTML parser se-powerful ini di standard library
- pandas: Menyediakan struktur data DataFrame yang powerful

Jawaban Nomor 2: Mengambil Keseluruhan Teks Artikel

Untuk mengambil keseluruhan teks pada artikel berita, ada dua cara:

Langkah-langkah:

5. Buka halaman web di browser
6. Klik kanan pada badan artikel, pilih "Inspect"

7. Cari tag HTML yang membungkus konten artikel
8. Pada detik.com: <div class="detail__body-text">

Cara 1: Menggunakan Class Tertentu

```
article_body = soup.find('div', class_='detail__body-text')
if article_body:
    full_text = article_body.get_text(separator='\n', strip=True)
    print(full_text)
```

Hasil: Total karakter yang diambil = 3108

Cara 2: Mengambil Semua Paragraf <p>

```
paragraphs = soup.find_all('p')
article_paragraphs = []
for p in paragraphs:
    text = p.get_text(strip=True)
    if len(text) > 50: # Filter paragraf pendek
        article_paragraphs.append(text)
```

Hasil: Ditemukan 14 paragraf, Total karakter = 2813

Jawaban Nomor 3: Web Scraping Halaman Web Lain

Website: <https://www.kompas.com/>

Target: Berita utama (headline) dari halaman depan

Langkah Menemukan Elemen:

9. Buka <https://www.kompas.com/> di browser
10. Klik kanan pada judul berita utama, pilih "Inspect"
11. Perhatikan struktur HTML
12. Judul berada dalam tag

Kode Implementasi:

```
import requests
from bs4 import BeautifulSoup
import pandas as pd

url = 'https://www.kompas.com/'
headers = {'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64)...'}

response = requests.get(url, headers=headers)
soup = BeautifulSoup(response.text, 'html.parser')

# Mengambil judul berita
headlines = soup.find_all('a', class_='article__link', limit=10)

news_data = []
for headline in headlines:
    title = headline.get_text(strip=True)
    link = headline.get('href', '')
    if title:
        news_data.append({'Judul': title, 'Link': link})
```

```
df = pd.DataFrame(news_data)
print(df)
```

Hasil Output:

Total berita ditemukan: 9

No	Judul	Link
1	Militer Israel Klaim Hancurkan Kantor Presiden...	video.kompas.com/...
2	3 Serangan dan 3 Lokasi dalam 60 Detik di Iran	kompas.id/artikel/...
3	Mendagri Sebut Kepemilikan Rumah Jadi Ukuran...	nasional.kompas.com/...
4	Bidik Masa Depan Hijau, Pemkot Semarang...	regional.kompas.com/...
5	Merajut Nadi Sumatera	vik.kompas.com/...

Ringkasan

Elemen yang Harus Dituliskan untuk Web Scraping:

Langkah	Keterangan
1. Inspect Element	Buka website → Klik kanan → Inspect
2. Identifikasi Tag	Perhatikan tag HTML (h1, div, a, p, dll)
3. Identifikasi Class/ID	Catat nilai class atau id
4. Gunakan di Kode	soup.find() atau soup.find_all()

Tips Penting:

- Setiap website memiliki struktur HTML yang berbeda
- Gunakan headers dengan User-Agent untuk menghindari blocking
- Beberapa website menggunakan JavaScript (perlu Selenium)
- Hormati robots.txt dan terms of service

Kesimpulan

Web scraping adalah teknik yang sangat berguna untuk mengekstrak data dari website secara otomatis. Dengan menggunakan library Python seperti requests, BeautifulSoup, dan pandas, proses scraping menjadi lebih mudah dan efisien. Penting untuk memahami struktur HTML dari website target dan mengidentifikasi elemen yang tepat untuk di-scrape.

Link Tugas [Tugas Web Scraping](#)